Medidas de Distância

Prof. Jefferson T. Oliva

Reconhecimento de Padrões (RC18EE)
Engenharia de Computação
Programa de Pós-Graduação em Engenharia Elétrica e de Computação (PPGEEC)
Universidade Tecnológica Federal do Paraná (UTFPR)
Campus Pato Branco

Sumário

- Distância Euclidiana
- Distância de Minkowski
- Distância de Mahalanobis
- Similaridade entre Vetores Binários
- Similaridade do Cosseno
- Propriedades Comuns de Distância e de Similaridade

Introdução

- Medidas de distância são utilizadas para quantificar a similaridade ou dissimilaridade em objetos ou conjuntos de exemplos em um conjunto de dados

- Diversas abordagens de aprendizado de máquina fazem o uso de medidas de distância:
  - Classificação
  - Agrupamento
  - Detecção de outliers
  - Redução de dimensionalidade

Introdução

- Similaridade
  - Determina o quão semelhantes são dois objetos
  - Quanto maior o valor da medida de distância, maior é a similaridade entre os objetos
  - Geralmente resultam em valores entre 0 e 1
- Dissimilaridade
  - Estabelece o quão diferentes são dois objetos
  - Quanto menor for o valor, maior é a similaridade entre o os objetos
  - O valor mínimo é 0, mas o limite superior varia (∞)
- Proximidade se refere à similaridade ou dissimilaridade

Introdução

- Diversas medidas podem ser utilizadas para o cálculo da similaridade/dissimilaridade
  - Distância Euclidiana
  - Distância de Manhattan
  - Distância de Minkowski
  - Distância de Mahalanobis
  - Coeficiente de casamento simples
  - Similaridade do cosseno
  - ...

Sumário

Distância Euclidiana

Distância Euclidiana

$$d(p,q) = \sqrt{\sum_{i=1}^{m}(p_i - q_i)^2}$$

onde m é o número de características, p_i e q_i são as i-ésimas características dos exemplos p e q, respectivamente

- Caso as escalas entre os atributos forem diferentes, é necessária a padronização dos seus respectivos valores

Distância Euclidiana

Exemplo	Atributo 1	Atributo 2
E1	0	3
E2	4	0
E3	2	2
E4	3	1
E5	1	1

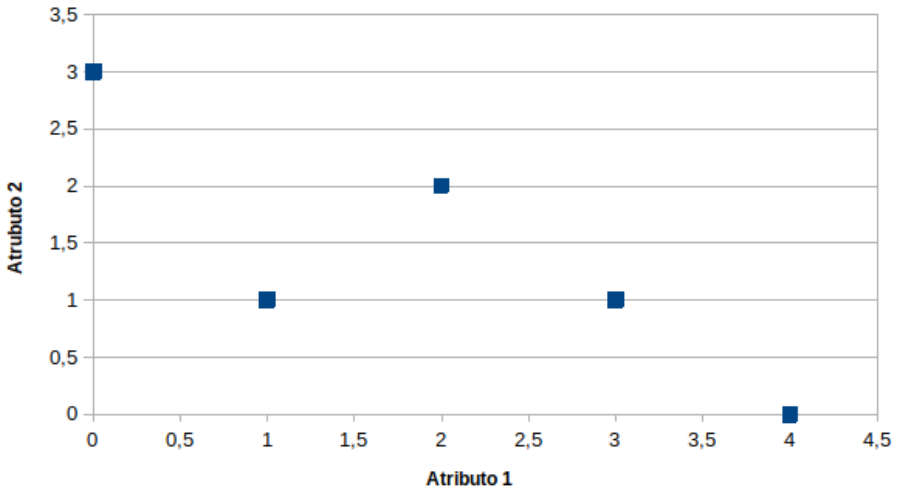

	E1	E2	E3	E4	E5
E1	0	5,00	2,24	3,61	2,24
E2	5,00	0	2,83	1,41	3,16
E3	2,24	2,83	0	1,41	1,41
E4	3,61	1,41	1,41	0	2,00
E5	2,24	3,16	1,41	2,00	0

Matriz de distâncias

Distância de Minkowski

Distância de Minkowski

- Generalização da distância Euclidiana

$$d(p,q) = \left[\sum_{i=1}^{m}(p_i - q_i)^r\right]^{\frac{1}{r}}$$

  - $r = 1$: distância de Manhattan (Norma L_1)
  - $r = 2$: distância Euclidiana (Norma L_2)
  - $r \to \infty$: distância de Chebyshev (Norma L_∞)

Distância de Minkowski

Exemplo	Atributo 1	Atributo 2
E1	0	3
E2	4	0
E3	2	2
E4	3	1
E5	1	1

L1	E1	E2	E3	E4	E5
E1	0	7,00	3,00	5,00	3,00
E2	7,00	0	4,00	2,00	4,00
E3	3,00	4,00	0	2,00	2,00
E4	5,00	2,00	2,00	0	2,00
E5	3,00	4,00	2,00	2,00	0

L2	E1	E2	E3	E4	E5
E1	0	5,00	2,24	3,61	2,24
E2	5,00	0	2,83	1,41	3,16
E3	2,24	2,83	0	1,41	1,41
E4	3,61	1,41	1,41	0	2,00
E5	2,24	3,16	1,41	2,00	0

L∞	E1	E2	E3	E4	E5
E1	0	5	2	3	2
E2	5	0	3	1	3
E3	2	2	0	1	1
E4	3	1	1	0	2
E5	2	3	1	2	0

Distância de Minkowski

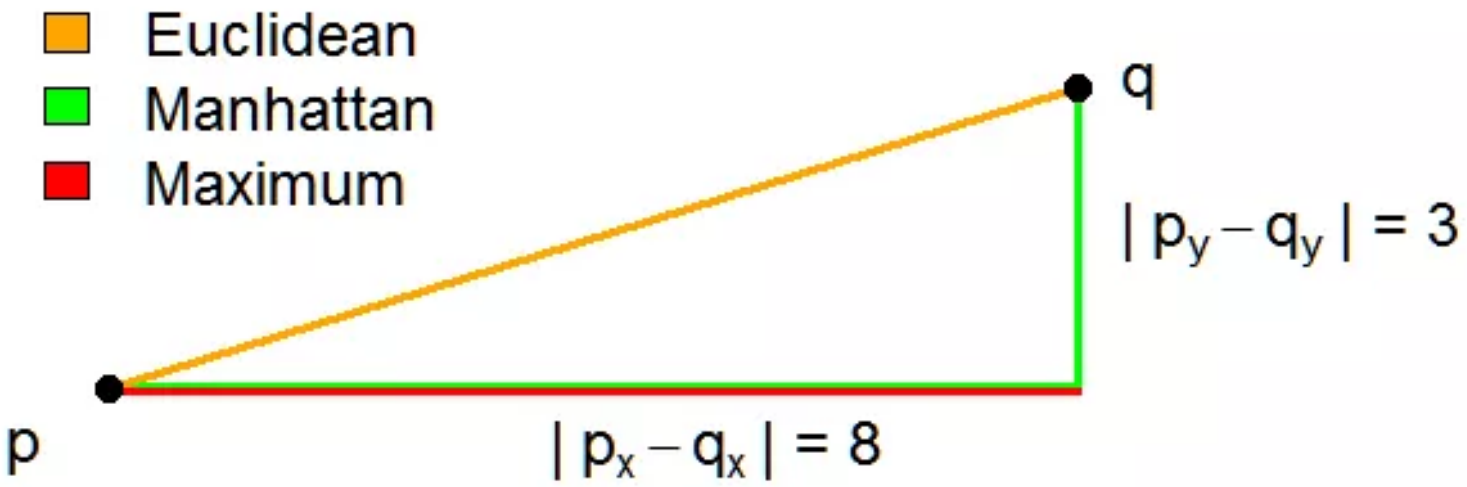

Distância de Minkowski

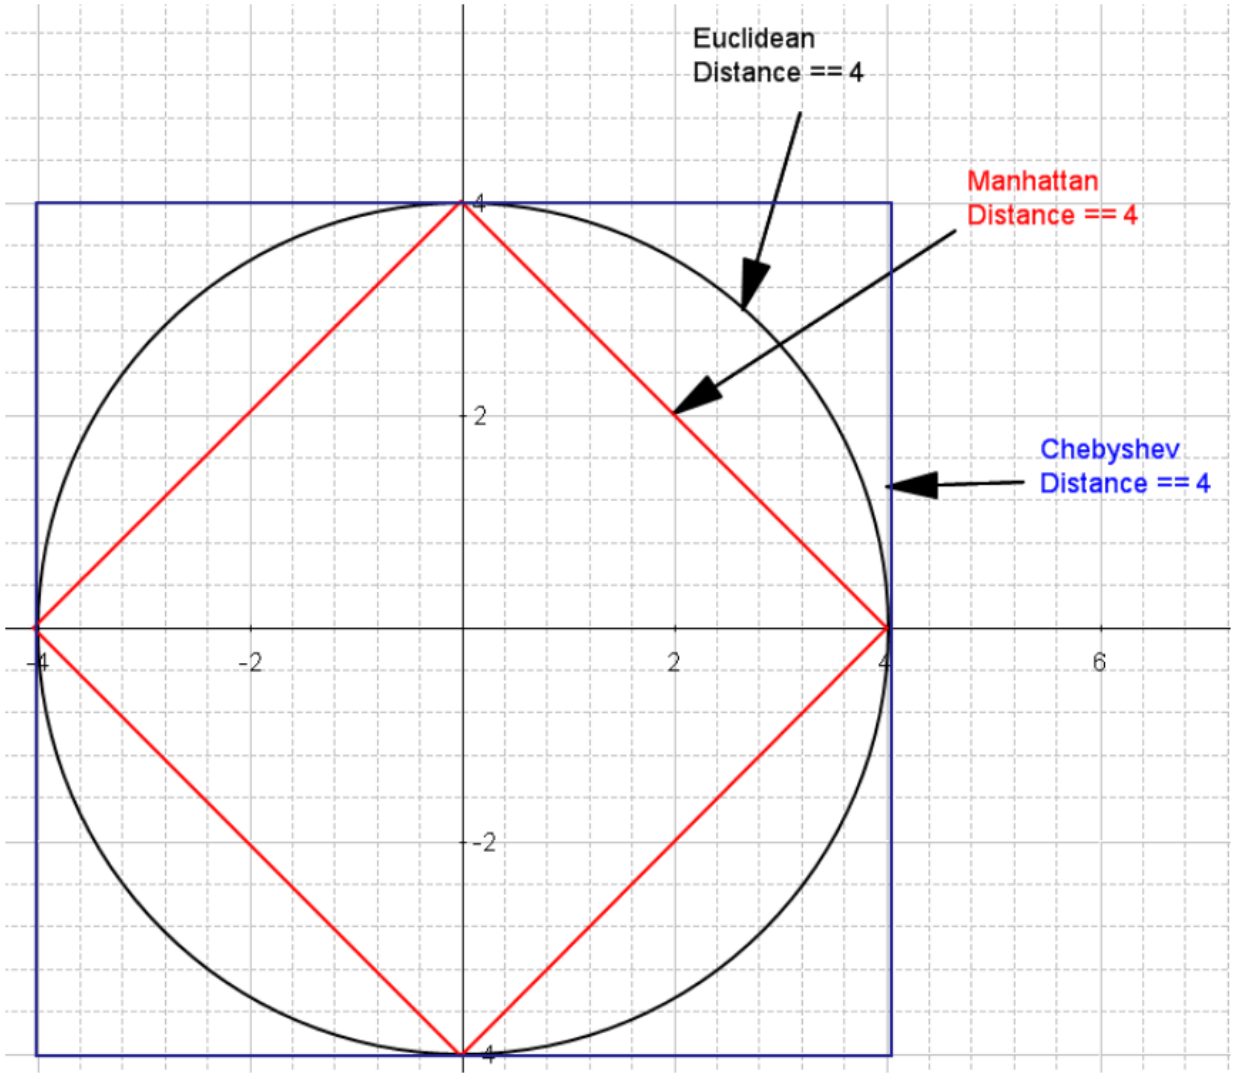

Distância de Mahalanobis

Distância de Mahalanobis

$$d(p,q) = \sqrt{(p-q)^T \sum^{-1} (p-q)}$$

- Onde:
  - $\sum$ é a matriz de co-variância da base de dados X

$$\sum_{i,j} = \frac{1}{n-1} \sum_{k=1}^{n} (x_{ki} - \overline{x_i})(x_{kj} - \overline{x_j})$$

  - Caso $\sum$ seja uma matriz identidade, a distância de Mahalanobis é a mesma que a Euclideana

- Essa medida de distância é útil para a detecção de *outliers*

Distância de Mahalanobis

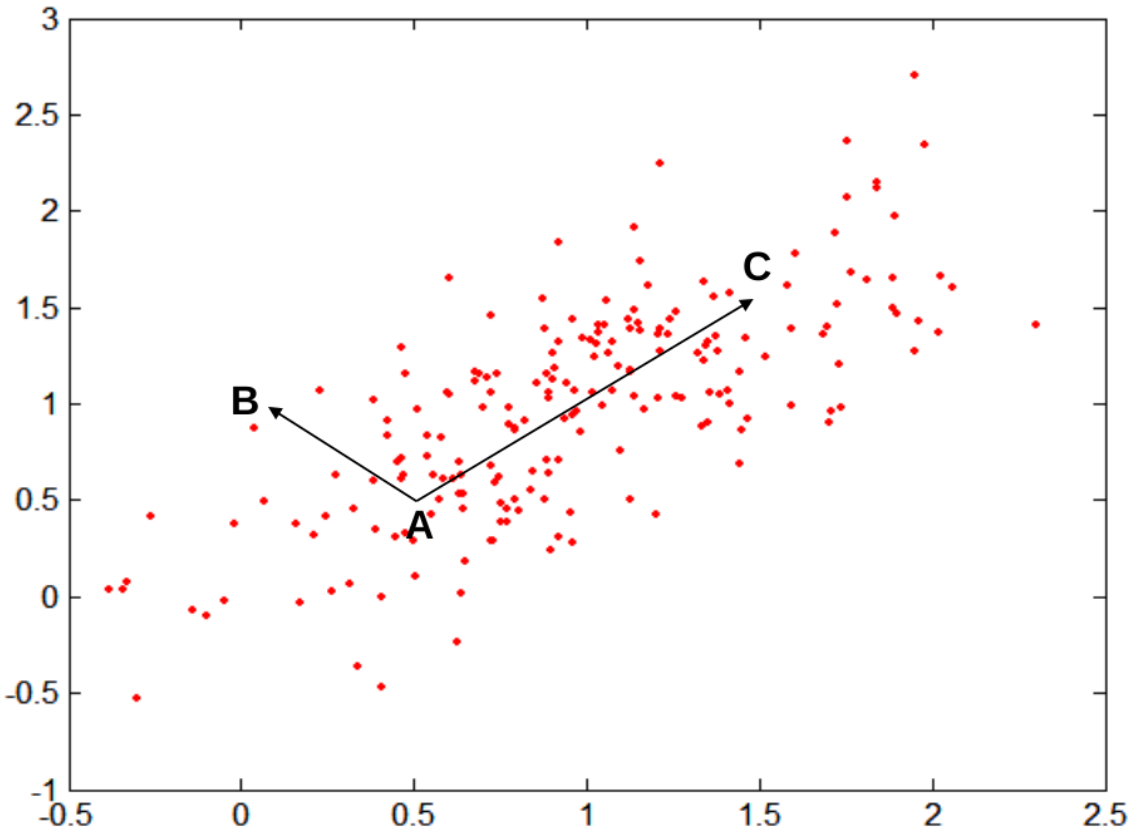

$$\Sigma = \begin{bmatrix} 0.3 & 0.2 \\ 0.2 & 0.3 \end{bmatrix}$$

A: (0.5, 0.5)

B: (0, 1)

C: (1.5, 1.5)

Mahal(A,B) = 5

Mahal(A,C) = 4

Similaridade entre Vetores Binários

Similaridade entre Vetores Binários

- Os exemplos comparados contêm apenas atributos binários
- Para mensurar a similaridade entre exemplos binários, são computados os seguintes parâmetros:
  - M_{00} número de atributos em que $p = 0$ e $q = 0$
  - M_{01} número de atributos em que $p = 0$ e $q = 1$
  - M_{10} número de atributos em que $p = 1$ e $q = 0$
  - M_{11} número de atributos em que $p = 1$ e $q = 1$
- Exemplos de medidas de distância: coeficiente de casamento simples e distância de Jaccard

Similaridade entre Vetores Binários

- Coeficiente de casamento simples

$$d(p,q) = \frac{M_{00} + M_{11}}{M_{00} + M_{10} + M_{01} + M_{11}}$$

  - Conta igualmente 0's e 1's
  - Adequada para atributos simétricos

- Distância (coeficiente) de Jaccard

$$d(p,q) = \frac{M_{11}}{M_{10} + M_{01} + M_{11}}$$

  - Ignora as ocorrências de pares de 0's (*e.g.* $p_i = p_j = 0$) para lidar adequadamente com atributos assimétricos
    - Afinal, 0 indica apenas a ausência de uma característica

Similaridade entre Vetores Binários

- Exemplo

  $$p = [1\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 0]$$
  $$q = [0\ 0\ 0\ 0\ 0\ 0\ 1\ 0\ 0\ 1]$$

  - $M_{00} = 7$
  - $M_{01} = 2$
  - $M_{10} = 1$
  - $M_{11} = 0$

- Coeficiente de casamento simples $= \frac{7+0}{7+2+1+0} = 0,7$
- Coeficiente de Jaccard $= \frac{0}{2+1+0} = 0$

Similaridade do Cosseno

Similaridade do Cosseno

- Comumente utilizada no processamento de linguagem natural
  - Os documentos são representados por vetores, onde cada atributo representa a frequência de ocorrência de uma palavra no texto

$$cos(p, q) = \frac{p \bullet q}{||p||.||q||}$$

onde

- é o produto interno entre os vetores

$||p||$ é a norma do vetor p

Similaridade do Cosseno

- Exemplo:

  p = [3 2 0 5 0 0 0 2 0 0]
  q = [1 0 0 0 0 0 0 1 0 2]

  - $p \bullet q = 3*1+2*0+0*0+5*0+0*0+0*0+0*0+2*1+0*0+0*2 = 5$
  - $||p|| = \sqrt{3^2+2^2+0^2+5^2+0^2+0^2+0^2+2^2+0^2+0^2} = \sqrt{42} = 6,48074069840786$
  - $||q|| = \sqrt{1^2+0^2+0^2+0^2+0^2+0^2+0^2+1^2+0^2+2^2} = \sqrt{6} = 2,449489742783178$
  - $cos(p,q) = \frac{5}{6,48074069840786*2,449489742783178} = 0,314970394174356$
  - Distância $= 1 - cos(p,q) = 0,685029605825644$

Propriedades Comuns de Distância e de Similaridade

- Medidas de distância, como a Euclidiana, possuem algumas propriedades bem conhecidas
  - $d(p, q) \geq 0$ para todo p e q
  - $d(p, q) = 0$ apenas se $p = q$
  - $d(p, q) = d(q, p)$ para todo p e q (simetria)
  - $d(p, r) \leq d(p, q) + d(q, r)$ para todo p, q e r (desigualdade triangular)

    Onde $d(p, q)$ é a distância (dissimilaridade) entre os exemplos p e q
  - Uma distância que satisfaz essas propriedades é considerada uma medida de distância

Propriedades Comuns de Distância e de Similaridade

- Medidas de similaridade também possuem algumas propriedades bem conhecidas:
  - $s(p, q) = 1$ (similaridade máxima) apenas se $p = q$
  - $s(p, q) = s(q, p)$ para todo p e q (simetria)

Onde $s(p, q)$ é a similaridade entre os exemplos p e q

Referências

CASANOVA, D.
Distance Measures. Aprendizado de Máquina.
Slides. Engenharia de Computação. Dainf/UTFPR, 2020.

RASCHKA, S.; MIRJALILI, V.
Python Machine Learning.
Packt, 2017.

TAN P.; STEINBACK M.; KUMAR V.
Introduction to Data Mining.
Pearson, 2006.